

ENTREGA 1 – Detección de enfermedades en hojas con CNN

Sebastian Castellanos Mejía - C.C 1001369003
scastellanos.mejia@udea.edu.co

1. Contexto de aplicación

La agricultura es una actividad esencial para el desarrollo económico y la seguridad alimentaria de muchas regiones del mundo. Sin embargo, los cultivos agrícolas están constantemente amenazados por una amplia variedad de enfermedades, muchas de las cuales afectan directamente el rendimiento y la calidad de los productos.

Tradicionalmente, la identificación de enfermedades en las plantas ha dependido del conocimiento empírico de los agricultores o del diagnóstico manual realizado por expertos. Este enfoque, además de ser lento y costoso, no siempre es accesible para pequeños productores o zonas rurales.

En este contexto, las tecnologías basadas en visión por computadora y aprendizaje profundo han emergido como herramientas innovadoras para automatizar el proceso de diagnóstico. El uso de modelos de redes neuronales convolucionales (CNN) permite procesar imágenes de hojas y detectar patrones asociados con enfermedades de forma rápida y precisa.

Este proyecto se enmarca en ese esfuerzo por aplicar inteligencia artificial en el ámbito agrícola, contribuyendo al desarrollo de soluciones tecnológicas que permitan mejorar la toma de decisiones en el manejo de cultivos, reducir pérdidas económicas y promover una agricultura más sostenible y eficiente.

2. Objetivo de Machine Learning

El objetivo principal de este proyecto es desarrollar un modelo de aprendizaje profundo capaz de identificar automáticamente enfermedades en hojas de plantas a partir de imágenes. Específicamente, se busca entrenar una red neuronal convolucional (CNN) que, dada la imagen de una hoja, pueda clasificarla en una de las siguientes categorías:

- Hoja sana
- Hoja afectada por Early blight
- Hoja afectada por Late blight

- Hoja afectada por Leaf mold

Este modelo tomará como entrada una imagen (preprocesada) y devolverá como salida la clase correspondiente, representando el tipo de enfermedad (o su ausencia). La solución se enfoca en el cultivo de tomate y está orientada a facilitar una detección rápida y precisa de enfermedades, que pueda escalar a herramientas móviles o plataformas accesibles para agricultores.

3. Dataset

Para este proyecto se utilizará el dataset **PlantVillage**, una base de datos pública ampliamente utilizada en investigaciones de visión por computadora aplicadas a la agricultura. Este dataset contiene más de 50,000 imágenes de hojas de plantas clasificadas según el tipo de cultivo y la enfermedad presente.

Para reducir la complejidad del problema y optimizar los recursos computacionales disponibles, se trabajará con un subconjunto del dataset enfocado exclusivamente en el cultivo de tomate, utilizando cuatro clases:

- **Tomato___Healthy**
- **Tomato___Early_blight**
- **Tomato___Late_blight**
- **Tomato___Leaf_Mold**

Características del dataset seleccionado:

- **Tipo de datos:** Imágenes en formato JPG
- **Número total de imágenes (estimado):** ~4,000
- **Tamaño aproximado en disco:** ~200 MB
- **Resolución de las imágenes:** Redimensionadas a 224x224 píxeles
- **Formato de entrada al modelo:** Tensor 3D (224 x 224 x 3)

Distribución de clases (estimada):

- Tomato___Healthy: ~1,000 imágenes
- Tomato___Early_blight: ~1,000 imágenes
- Tomato___Late_blight: ~1,000 imágenes
- Tomato___Leaf_Mold: ~1,000 imágenes

Esta distribución relativamente equilibrada entre clases favorece el entrenamiento de modelos sin necesidad de aplicar técnicas adicionales de balanceo en una primera iteración.

4. Métricas de desempeño

Para evaluar el rendimiento del modelo y su aplicabilidad en escenarios reales, se considerarán tanto métricas técnicas propias del aprendizaje automático como métricas relacionadas con el impacto potencial en el sector agrícola.

4.1 Métricas de aprendizaje automático (ML)

Estas métricas permitirán medir la precisión y robustez del modelo entrenado:

- **Accuracy:**
Porcentaje de predicciones correctas sobre el total de muestras evaluadas. Es útil cuando las clases están balanceadas, como en este caso.
- **Matriz de confusión:**
Representación visual que muestra los aciertos y errores del modelo por clase, permitiendo identificar confusiones frecuentes entre enfermedades.
- **Precision, Recall y F1-score por clase:**
Métricas complementarias para evaluar el desempeño del modelo por categoría, especialmente útiles en escenarios donde una enfermedad puede tener consecuencias más graves que otra.

4.2 Métricas de negocio / impacto

Estas métricas se relacionan con el valor práctico que tendría el modelo si se implementara en un entorno agrícola:

- **Reducción del tiempo de diagnóstico:**
El uso de un modelo automático puede reducir de horas a segundos el tiempo

necesario para identificar una enfermedad en campo.

- **Cobertura diagnóstica sin necesidad de expertos:**
Permite a pequeños agricultores acceder a diagnósticos confiables sin depender de especialistas o laboratorios costosos.
- **Prevención de pérdidas en cultivos:**
Una detección temprana permite aplicar tratamientos a tiempo, reduciendo el daño al cultivo y minimizando pérdidas económicas.

5. Referencias y resultados previos

El dataset PlantVillage ha sido ampliamente utilizado en investigaciones académicas y proyectos de clasificación de enfermedades en plantas mediante redes neuronales convolucionales. A continuación, se presentan algunas referencias y resultados relevantes:

- **Hughes & Salathé (2015)** – *"An open access repository of images on plant health to enable the development of mobile disease diagnostics"*
Este trabajo introdujo oficialmente el dataset PlantVillage y sentó las bases para su uso en modelos de clasificación de imágenes. [DOI: 10.1371/journal.pone.0143882]
- **Mohanty, Hughes & Salathé (2016)** – *"Using deep learning for image-based plant disease detection"*
En este estudio se entrenaron varias redes CNN, incluyendo AlexNet y GoogLeNet, obteniendo **precisiones superiores al 99%** en la clasificación de 14 tipos de cultivos y 26 enfermedades.
[arXiv:1604.03169](https://arxiv.org/abs/1604.03169)
- **Ferentinos (2018)** – *"Deep learning models for plant disease detection and diagnosis"*
Evaluó CNNs más modernas como VGG, ResNet y AlexNet, reportando **precisiones entre 97% y 99%** al trabajar con PlantVillage.
Computers and Electronics in Agriculture, 145, 311-318.

Estos resultados confirman que las redes convolucionales son altamente efectivas para tareas de clasificación de enfermedades en hojas, incluso utilizando arquitecturas estándar. El presente proyecto se basa en estos antecedentes y buscará validar resultados similares, priorizando un modelo eficiente y funcional desde una etapa temprana del desarrollo.